

DELLIDJ

ANIS

FI

Rapport du projet de clustering

1.Introduction

La reconnaissance d'activités humaines à partir de capteurs de smartphone est un enjeu important pour de nombreuses applications. Dans ce projet, nous cherchons à classifier automatiquement des séries temporelles correspondant à différentes activités physiques (marche, montée d'escaliers, descente d'escaliers, position assise, position debout, position allongée), sans utiliser les étiquettes réelles lors de l'apprentissage. Pour cela, nous appliquons plusieurs méthodes de classification non supervisée et analysons leur capacité à retrouver les différentes activités à partir des signaux bruts.

2.Tехнике utilisées

Dans cette étude 4 techniques ont été utilisées :

kmeans

DBSCAN

K-shape

DBA-Kmeans

2.1.kmeans & DBSCAN

Pour analyser nos données, nous appliquons deux méthodes de clustering aux principes différents : **KMeans**, basé sur la recherche de centres, et **DBSCAN**, qui construit les groupes selon la densité et détecte le bruit.

Resultat kmeans

- **Silhouette = 0.088**

Le coefficient de silhouette mesure la **qualité de séparation des clusters**.

Il varie entre **-1 et 1** :

- proche de 1 → clusters bien séparés
- proche de 0 → clusters qui se chevauchent
- négatif → mauvais clustering

Avec 0.088, les clusters sont presque confondus.

Cela signifie :

- les activités produisent des signaux très proches,
- les frontières entre clusters sont floues,
- les séries temporelles des activités statiques (assis/debout/allongé) sont difficiles à distinguer.

En résumé : **KMeans ne parvient pas à créer des groupes bien séparés dans l'espace des variables.**

- **ARI = 0.405**

L'ARI (*Adjusted Rand Index*) compare les clusters trouvés avec les vraies classes.

- 1 → correspondance parfaite
- 0 → correspondance aléatoire
- négatif → pire que du hasard

Un ARI de 0.405 est moyen, mais relativement correct en clustering non supervisé.

Cela montre que :

- KMeans arrive à retrouver certaines activités **dynamiques** : marche, montée, descente.
- mais **confond fortement les postures statiques**, dont les signaux sont très similaires.

Bilan KMeans :

- Séparation faible (silhouette basse)
- Cohérence partielle avec les vraies classes (ARI moyen)

Resultat DBSCAN

- **Clusters trouvés = 8**

DBSCAN forme des clusters en fonction de la densité.

Le fait qu'il produise **8 clusters** alors que les vraies classes sont **6 activités** montre que :

- les données ne présentent pas des zones de densité bien définies,
- l'algorithme découpe les données en petits sous-groupes,
- il interprète une partie des variations naturelles comme des "clusters".

DBSCAN n'arrive pas à capturer la structure réelle des activités.

- **ARI = 0.148**

C'est un score très faible.

Cela signifie :

- **forte confusion entre les clusters trouvés et les vraies activités,**
- les groupes créés par DBSCAN **ne correspondent quasiment pas** aux classes réelles.

Les raisons principales :

- les signaux des activités ne forment pas des zones de densité nette,
- DBSCAN n'est pas adapté aux séries temporelles sans transformation préalable,
- l'échelle et la dynamique des signaux brouillent la notion de "densité".

Bilan DBSCAN :

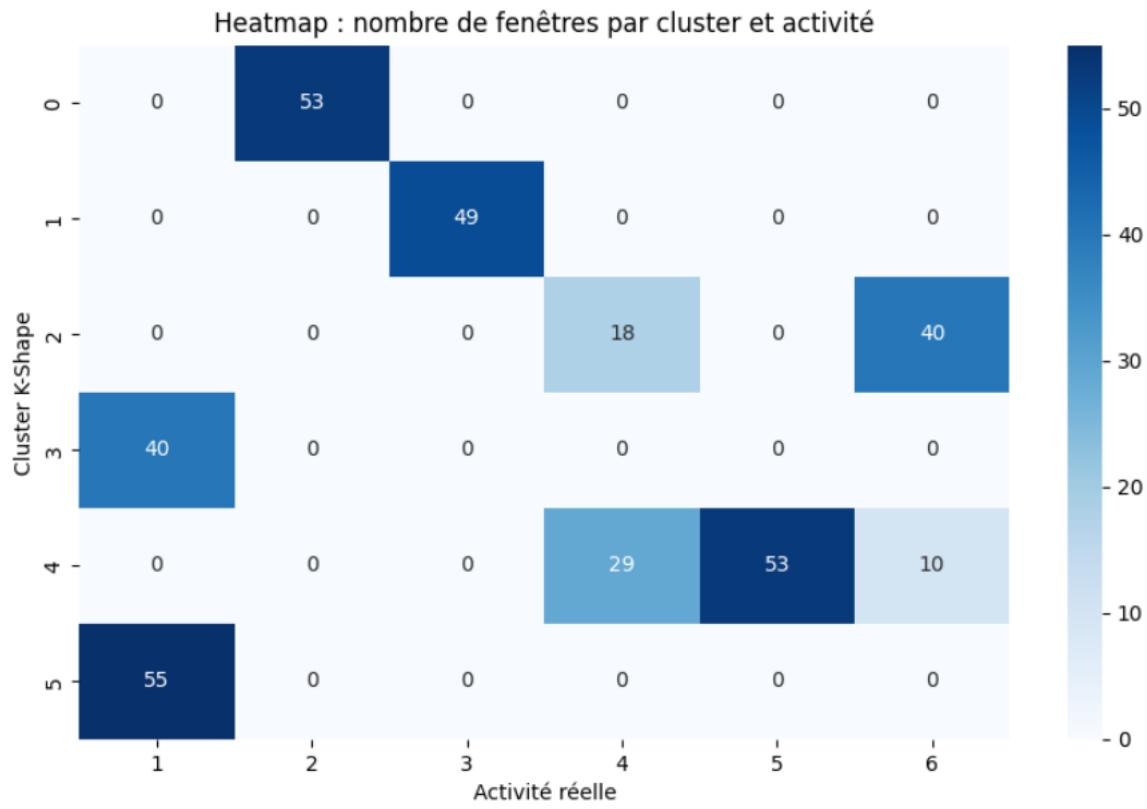
- Beaucoup de clusters incohérents
- Très faible correspondance avec les étiquettes réelles

Conclusion

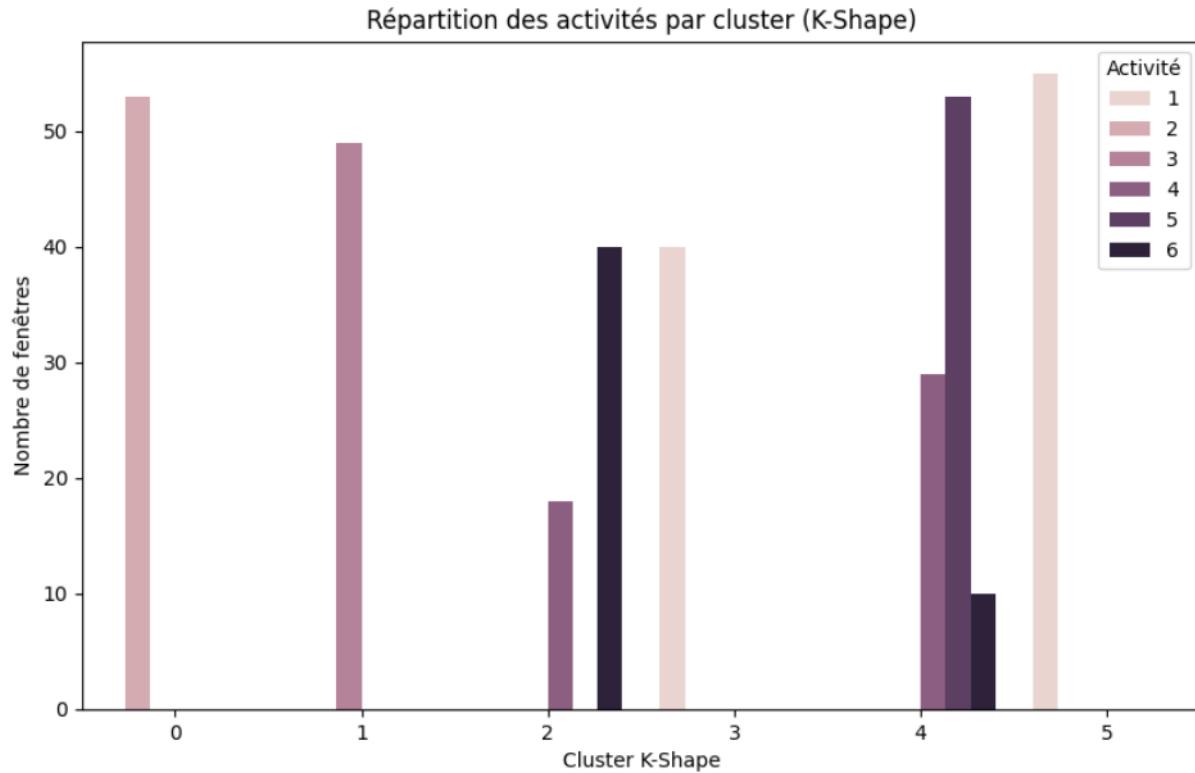
Même si K-Means donne de meilleurs résultats que DBSCAN, avec une correspondance partielle aux vraies classes et une identification correcte de certaines activités dynamiques, aucune des deux méthodes ne permet de produire un clustering satisfaisant. Les clusters restent mal séparés et les postures statiques sont largement confondues, ce qui montre que ni KMeans ni DBSCAN ne sont adaptés à ce jeu de données.

2.2. Interprétation des résultats de K-Shape

L'algorithme K-Shape obtient un Adjusted Rand Index (ARI) de **0.647**, ce qui traduit une concordance globalement bonne entre les clusters produits et les classes réelles, bien que moins élevée que celle obtenue avec DBA-KMeans. Comme l'ARI est compris entre -1 et 1, une valeur supérieure à 0.6 indique que la structure trouvée par le clustering reflète de manière satisfaisante les activités observées, même si certains mélanges persistent entre certaines classes. Ici, l'ARI montre que K-Shape parvient à regrouper correctement une majorité de fenêtres appartenant à une même activité, tout en produisant davantage de confusion que les méthodes basées sur DTW. Les visualisations (heatmap et histogramme) permettent d'analyser plus finement ces résultats.



La heatmap permet d'examiner la répartition réelle des activités dans chaque cluster. On observe que le cluster 0 regroupe presque exclusivement l'activité 2, avec 53 fenêtres, ce qui indique une séparation nette. Le cluster 1 contient essentiellement les fenêtres de l'activité 3 (49 occurrences), traduisant une bonne homogénéité interne. Le cluster 2 présente une forte confusion entre les activités assise et allongée : il contient 18 fenêtres de l'activité 4 et 40 de l'activité 6. C'est le cluster le moins homogène, ce qui s'explique par la grande similarité des deux postures en termes de forme normalisée des signaux. Le cluster 3 regroupe majoritairement l'activité 1 avec 40 fenêtres, tandis que le cluster 4 contient principalement l'activité 5 (53 occurrences). Enfin, le cluster 5 est composé de 55 fenêtres, elles aussi associées à l'activité 1. Ainsi, la heatmap montre que K-Shape distingue très bien les activités dynamiques (marche, montée, descente), et identifie correctement plusieurs postures statiques, malgré une confusion marquée entre assis et allongé.



Heatmap : nombre de fenêtres par cluster et activité

L'histogramme conforte ces observations puisqu'il met en évidence que chaque cluster est dominé par une activité spécifique. Les activités dynamiques sont bien séparées en clusters distincts, tandis que les postures statiques s'organisent de manière globalement cohérente, avec à nouveau un chevauchement important entre les positions assise et allongée. Aucun cluster n'est vide, ce qui confirme que le nombre de clusters retenu est pertinent et pleinement exploité par l'algorithme. De manière générale, K-Shape, qui repose sur la mesure de similarité basée sur la forme (SBD) et sur l'alignement des séries normalisées, se révèle adapté pour analyser des signaux inertIELS présentant des motifs dynamiques clairs. Il parvient à capturer correctement les formes caractéristiques des activités physiques, en particulier les mouvements périodiques. Sa principale limite concerne la difficulté à séparer les postures statiques très proches, notamment assis et allongé, car la normalisation réduit les différences d'amplitude. Globalement, les résultats obtenus montrent que K-Shape est une méthode efficace pour réaliser un clustering sur des séries temporelles.

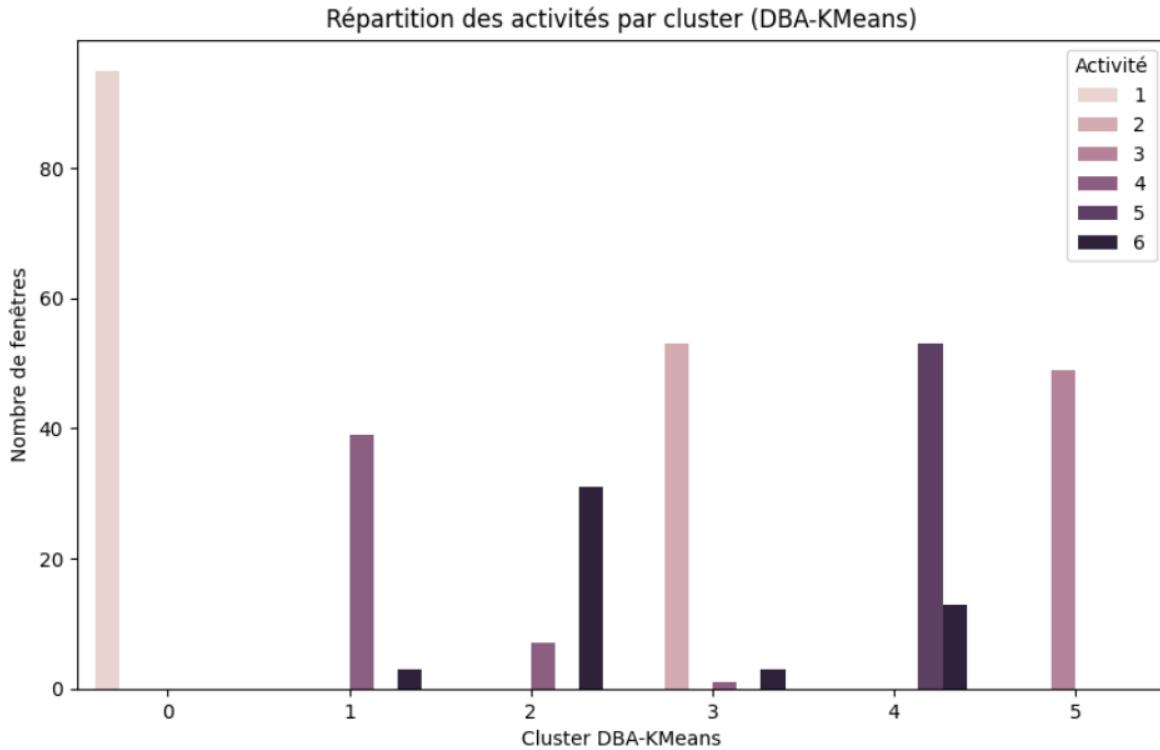
2.3. Interprétation des résultats de résultats de DBA-KMeans

L'algorithme DBA-KMeans obtient un **Adjusted Rand Index (ARI) de 0.874**, ce qui traduit une très bonne concordance entre les clusters produits et les classes réelles. Comme l'ARI est compris entre -1 et 1, une valeur proche de 1 signifie que la structure trouvée par le clustering correspond presque parfaitement à la vérité terrain. Ici, l'ARI élevé indique que DBA-KMeans parvient à regrouper correctement les fenêtres appartenant à une même activité, qu'il produit très peu de

mélange entre classes différentes, et que la structure générale des clusters reflète fidèlement les activités observées. Les visualisations (heatmap et histogramme) confirment cette cohérence globale.



La heatmap permet d'examiner la répartition réelle des activités dans chaque cluster. On observe que le cluster 0 regroupe presque exclusivement l'activité *marche*, avec 95 fenêtres, ce qui montre que cette activité est isolée de manière nette. Le cluster 1 contient majoritairement des fenêtres correspondant à la position *assise*, avec quelques cas appartenant à l'activité *allongée*, tout en restant globalement cohérent. Le cluster 2 présente un mélange plus marqué entre les activités *assis* et *allongé* ; c'est le cluster le moins homogène, ce qui s'explique par la proximité des deux postures en termes de dynamique des signaux. Le cluster 3 correspond principalement à la *montée d'escaliers*, avec 53 fenêtres, tandis que le cluster 4 regroupe surtout des fenêtres associées à la position *debout*. Enfin, le cluster 5 est presque entièrement constitué de fenêtres correspondant à la *descente d'escaliers*. Ainsi, la heatmap montre que l'algorithme distingue très bien les activités dynamiques (marche, montée, descente), et qu'il identifie également correctement les postures statiques, à l'exception d'une confusion attendue entre les positions *assise* et *allongée*.



L'histogramme conforte ces observations puisqu'il met en évidence que chaque cluster est dominé par une activité spécifique. Les activités impliquant un mouvement sont parfaitement isolées dans des clusters distincts, tandis que les postures statiques s'organisent de façon globalement cohérente, à nouveau avec un léger chevauchement entre assis et allongé. Aucun cluster ne reste vide, ce qui montre que le nombre de clusters retenu est pertinent et exploité efficacement par l'algorithme.

De manière générale, DBA-KMeans, qui repose sur la distance DTW et sur la construction de barycentres temporels, se révèle particulièrement adapté pour analyser des signaux provenant de capteurs inertIELS. Il parvient à capturer correctement les formes et les dynamiques caractéristiques des différentes activités. Ses principaux atouts sont la très bonne séparation des activités dynamiques et l'identification fiable de plusieurs postures statiques. La seule réelle limite observée concerne la confusion entre les positions assise et allongée, qui se manifeste dans un cluster commun et s'explique par la faible amplitude et la similarité des signaux associés à ces deux postures. Globalement, les résultats obtenus démontrent que DBA-KMeans est une méthode efficace pour réaliser un clustering sur des séries temporelles issues de mesures d'accélération.

3. Conclusion générale

Dans l'ensemble, les différentes méthodes de clustering appliquées aux séries temporelles issues des capteurs inertIELS montrent des niveaux de performance contrastés, révélant l'importance du choix de la métrique et du modèle pour capturer la dynamique des activités humaines. Les approches classiques telles que K-Means, qui reposent sur la distance euclidienne, obtiennent des résultats modestes, avec un ARI de 0.405 et un coefficient de silhouette très faible (0.088). Ces deux indicateurs confirment que K-Means peine à représenter correctement la structure

temporelle des signaux : les activités dynamiques, fortement non linéaires, ainsi que les postures statiques de faible amplitude, ne peuvent être séparées efficacement par une simple distance euclidienne appliquée point à point. DBSCAN présente des performances encore plus limitées, avec un ARI de 0.148 et un découpage en 8 clusters peu exploitables. L'algorithme a tendance à produire de nombreux petits groupes et du bruit, ce qui montre qu'il est très sensible aux paramètres ϵ et minPts, et que sa capacité à identifier des motifs temporels cohérents est insuffisante dans ce contexte.

À l'inverse, les méthodes spécifiquement conçues pour les séries temporelles se révèlent nettement plus performantes. K-Shape, basé sur la mesure de similarité shape-based distance (SBD), atteint un ARI de 0.647 et parvient à regrouper correctement la majorité des activités présentant des formes de signaux distinctives. Les activités dynamiques, telles que la marche ou la montée d'escaliers, sont bien séparées, tandis que les postures statiques sont globalement bien identifiées, malgré une confusion persistante entre assis et allongé. Finalement, DBA-KMeans se distingue comme la méthode la plus performante, avec un ARI de 0.874, traduisant une très forte concordance entre clusters et classes réelles. La combinaison de la distance DTW et du calcul de barycentres temporels (DBA) permet de capturer efficacement les déformations temporelles, les variations d'amplitude et la structure cyclique des signaux, offrant une séparation presque parfaite des différentes activités.

Ainsi, ce projet montre clairement que les méthodes de clustering adaptées aux séries temporelles surpassent largement les approches standards reposant sur la distance euclidienne. Les résultats soulignent l'importance de tenir compte des propriétés intrinsèques des signaux inertIELS — alignement temporel, forme des motifs, variabilité intra-classe — pour obtenir une classification non supervisée pertinente. Parmi les méthodes testées, DBA-KMeans apparaît comme la plus efficace et la plus robuste pour la détection non supervisée d'activités humaines.